

1. Prezentacja Computer Vision (Seminarium z Robotyki)

2. Możliwości jakie daje obserwacja otoczenia

AI system pokonał najlepszych doktorów z Chin , w 2 etapowych zawodach wykrywania guza mózgu. Model dawał poprawne przewidywania w 87% przypadków. I zajęło mu 15minut zdiagnozowanie 225 zdjęć. Doktorzy natomiast zdobyli 66% dokładność w czasie 30 minut.

W drugiej rundzie zajęli się innym tematem i także zdecydowanie wygrał model AI.

3. Przepływ informacji

opis zdjęcia

4. Sieci Sjamskie

Dwa wektory wrzucamy do funkcji straty, która sprawdza także jakie są etykiety dwóch obrazów wejściowych.

+ Całkiem inne liczby z wyglądu powinny być zdekodowane na wektory których końcowe groty są od siebie daleko.

+ Podobne liczby będą osadzone w przestrzeni bliżej siebie.

Contrastive loss: odległość pomiędzy różnymi kategoriami zdjęć jest :

- powiększana gdy etykiety zdjęć są różne
- zmniejszana gdy etykiety zdjęć są takie same.

Po kroku Forward Propagation i wyliczeniu funkcji straty następuje Backward propagation, gdzie (sieć jest uczona podobieństwa między zdjęciami).

5. ciekawe przykłady z życia wzięte

Sytuacja: Jako że wojskowe standardy technologiczne są bardzo wysokie, chcemy zaprojektować model który będzie rozpoznawał czołgi. Tak aby na polu bitwy było jasne że strzelamy w przeciwnika, a nie w naszych.

Wojskowi specjaliści aby wyuczyć model potrzebowali zdjęć. Pojechali więc w dwa miejsca i przygotowali zestaw zdjęć dla dwóch rodzajów czołgów. (zdjęcia widoczne na ekranie).

Pytanie: Czy system rozpoznawania dobrze nauczył się rozpoznawać czołgi? Odpowiedź brzmi : najprawdopodobniej nie.

Kolejna sytuacja: Konferencja Barcelona 2016r. Ankieta puszczona dla uczestników konferencji miała na celu sprawdzić, jak sądzą czy model bazujący na tego typu zdjęciach mógł dobrze nauczyć się rozróżniać Husky od Wilka.

Wniosek: zdjęcia którymi uczymy model muszą być odpowiednio przygotowane. Jak źle nauczymy to będzie źle działał.

6. scena z manipulatorem

Teraz spróbujemy zastosować nasz system w środowisku produkcyjnym.

Nauczyliśmy się już rozpoznawać obiekty ze sceny (robi to ta kamera na chwytaku manipulatora.)

Kinect służy także do rozpoznawania obiektów na scenie. Dodatkowo jest on kamerą 3D , a więc skanując nim otoczenie mamy dodatkową informację w postaci głębi przestrzennej skanowanego otoczenia.

7. czułość precyzja

Czułość : stanowi prawdopodobieństwo sytuacji w której rzeczywiste wystąpienie klasy 1 zostanie właściwie rozpoznane.

$TP / TP+FN$

(medycyna)

Precyzja : prawdopodobieństwo pokrywania się przewidywań modelu i rzeczywistej klasy, gdy próba należy do klasy 1.

$TP / TP+FP$

macierz pomyłek:

(confucion matrix)

8. Segmentacja: Samochód: wykrywanie obiektów

WYkrywanie obiektów polega na jednoczesnej lokalizacji i identyfikacji obiektu obecnego na obrazie.

Identyfikacja jest klasycznym zadaniem rozpoznawania lub klasyfikacji w komputerowym widzeniu. Minimalnym wymaganiem stawianym metodzie wykrywania obiektów, jest określenie czy obwiednia należy do znanego obiektu czy do tła.

W identyfikacji ważna jest czułość i precyzja.

Najnowocześniejsze metody wykrywania obiektów działają w czasie rzeczywistym – single shot detection (bez znaczącego pogorszenia wydajności).

9. Czym charakteryzuje się dobra sieć do wykrywania obiektów?

Odporna na zakłucenia w rzeczywistym środowisku

+ słabe oświetlenie

+ obraz prześwietlony

+ zagracone tło

+ transformacja obiektów

(obrócony)

10. Transfer Learning

Aby wynajdywać koła na nowo (tzn budować modelu od zera) , z pomocą przychodzi nam transfer learning.